

Проявляются ли конструкции в распределениях слов?

Global affinity якорей Русского конструктикона в модели ruRoberta-large

Проход 1 · 23.09.2026

Аннотация. Мы переносим метрику *global affinity* из работы Rozner, Weissweiler, Mahowald и Shain (EMNLP 2025) на русский язык: это вероятность, которую маскированная языковая модель присваивает исходному слову, если замаскировано только оно. На 30 конструкциях Русского конструктикона (150 примеров) и модели ai-forever/ruRoberta-large проверена гипотеза о том, что фиксированные слова конструкций (якоря) предсказуемы по контексту лучше, чем слова в открытых слотах, и лучше, чем те же словоформы вне конструкции. Обе базовые линии гипотезу поддерживают: медиана affinity якорей 0,95 против 0,44 у заполнителей (Cliff's $\delta = 0,39$, 95% ДИ [0,20; 0,57]), якоря выше в 20 из 27 конструкций; та же словоформа внутри конструкции предсказуемее, чем в предложениях НКРЯ (+0,11 [0,04; 0,18], Уилкоксон $p = 0,008$). Однако эффект неоднороден: он держится на конструкциях со служебными и смешанными якорями, а у конструкций только со знаменательными якорями якоря не предсказуемее заполнителей ($\delta = -0,13$, н.з.).

1. Введение

Rozner и соавт. предлагают смотреть на конструкции через распределения, которые маскированная языковая модель предсказывает для отдельных позиций. В их §5.1 показано, что фиксированные слова конструкций имеют высокую *global affinity*: модель уверенно восстанавливает такое слово, даже когда оно полностью скрыто. Здесь этот результат воспроизводится на русском языке, с другой моделью и другими данными. Вместо CoGS используется Русский конструктикон, вместо roberta-large используется ai-forever/ruRoberta-large.

Проверяется три утверждения:

1. якоря имеют более высокую *global affinity*, чем заполнители слотов в тех же предложениях;
2. та же словоформа предсказуемее внутри конструкции, чем вне её (предложения из НКРЯ);
3. эффект не сводится к части речи: якоря чаще служебные слова, которые предсказуемы сами по себе.

2. Данные и метод

2.1. Конструкции

Из Русского конструктикона (4001 конструкция, CC BY 4.0) заранее отобран фиксированный список из 30 конструкций, по одной на каждую комбинацию «топ-10 синтаксических типов × тип якорей» (func: только служебные, content: только знаменательные, mixed: оба). У каждой конструкции 5 примеров со скобочной разметкой слотов, например «Тогда это было отстающее село, откуда люди [разъезжались]_{Action} кто куда». Всего 150 примеров и 1511 слов. Из них 261 якорь, 536 заполнителей и 714 прочих слов (прочие через модель не прогоняются).

Слово считается заполнителем, если оно попадает в размеченный слот. Якорем слово считается, если оно стоит вне слотов и совпадает с якорем конструкции по словоформе (237 случаев). Поле паде конструктикона не помечает изменяемые якоря тегом вида знать-Pst: якоря «стать», «счесть», «развязать», «легкий» записаны словарной формой, а в примерах встречаются в формах «стал», «сочла», «развязал», «легкой». Поэтому для знаменательных якорей в словарной форме добавлено сопоставление по лемме (руmorphу3, 19 случаев). Слово «худобедно» сопоставляется как составное (5 случаев).

2.2. Модель и global affinity

Используется ai-forever/ruRoberta-large (355M параметров, ВВРЕ-словарь на 50 257 токенов) с зафиксированной ревизией 5192d064. Слова сопоставляются с токенами через offset_mapping fast-токенизатора. Проверок в духе [a-zA-Z], которые в коде авторов ломаются на кириллице, нет. Считаются три варианта:

- **single** (как в статье): для однотокенного слова это $\text{softmax}(\text{logits})[\text{orig_id}]$ при маскировании этого токена. Мультитокенные слова пропускаются.
- **chain** (расширение для мультитокенных слов): маскируются все k подтокенов, после чего они по одному раскрываются слева направо: $P(w) = \prod_i P(t_i \mid \text{контекст}, t_{<i}, [M]_{>i})$, ср. PLL-word-l2r у Kauf и Ivanova (2023). При $k = 1$ вариант совпадает с single, и это проверено юнит-тестом.
- **lemma** (только для однотокенных якорей): сумма вероятностей всех однотокенных элементов словаря с той же леммой и тем же префиксом пробела. Это нижняя оценка.

2.3. Базовая линия вне конструкции (НКРЯ)

Для каждой из 60 словоформ-якорей, реально встретившихся в примерах, через API НКРЯ взято до 50 предложений основного корпуса с этой формой, всего 2891 предложение. Выброшены предложения, где вместе с формой встречаются все остальные якоря хотя бы одной её конструкции (например, «я» + «смотрю»). Для конструкций с одним якорем такой фильтр невозможен; это касается 23 форм из 60.

2.4. Статистика

Основное сравнение: пул слов (Mann–Whitney U, Cliff’s δ) и уровень конструкций (разность «средняя affinity якорей минус средняя affinity заполнителей», sign test). Доверительные интервалы получены бутстрапом по конструкциям (10 000 повторов), потому что слова внутри конструкции зависимы. Сравнение «внутри vs вне» проведено по словоформам: тест Уилкоксона, rank-biserial корреляция и бутстрап по формам.

3. Результаты

3.1. Якоря против заполнителей




Рис. 1. Эмпирические функции распределения global affinity. Точки — медианы. Ось X симметрично-логарифмическая.

Вариант	п як. / зап.	Медиана як. / зап.	Cliff's δ [95% ДИ]	Як. > зап.	Sign p
single	224 / 406	0,954 / 0,440	0,39 [0,20; 0,57]	20 из 27	0,019
chain	261 / 536	0,884 / 0,240	0,38 [0,20; 0,54]	22 из 30	0,016

Таблица 1. Якоря против заполнителей. «Як. > зап.» — число конструкций, где средняя affinity якорей выше. Mann-Whitney $p < 10^{-15}$ в обоих вариантах. Средняя разность на уровне конструкций: 0,26 [0,13; 0,39] (single) и 0,23 [0,11; 0,36] (chain).

Якоря заметно предсказуемее заполнителей (Рис. 1, Таблица 1). В single-режиме affinity выше 0,5 у 76% якорей и у 48% заполнителей. Переход к chain добавляет мультитокенные слова (14% якорей и 24% заполнителей) и выводов не меняет. Мультитокенные слова в среднем менее предсказуемы, поэтому медианы в chain ниже, а размер эффекта почти тот же.

3.2. Контроль части речи и неоднородность эффекта




Рис. 2. Медианы affinity (chain) якорей и заполнителей в срезах по классу части речи слова (ру morphology3) и по типу якорей конструкции, заданному при отборе.

Главное смешение: якоря чаще служебные слова (52%), а заполнители чаще знаменательные (74%). Внутри одного класса части речи эффект сохраняется, но слабее (Рис. 2, Таблица 2). У знаменательных слов медиана якорей 0,49 против 0,06 у заполнителей ($\delta = 0,30$, $p < 0,001$). У служебных обе группы у потолка (0,98 против 0,97), разница небольшая, но значимая ($\delta = 0,18$, $p = 0,009$).

Самый важный срез задан дизайном отбора. У конструкций со служебными (func) и смешанными (mixed) якорями эффект большой: $\delta \approx 0,55$. У конструкций только со знаменательными якорями (content) эффекта нет: медиана якорей 0,36 против 0,45 у заполнителей, $\delta = -0,13$, $p = 0,12$. В single-режиме картина та же ($\delta = -0,08$). Эти конструкции видны внизу Рис. 3: «худо-бедно», «развязать NP-Асс», «Сто пудов/стопудово XP», «легкий Noun». Во всех этих случаях якорь — редкое знаменательное слово или идиома, которое модель по контексту не восстанавливает.

Срез (chain)	п як. / зап.	Медиана як. / зап.	Cliff's δ	MW p
знаменательные слова	125 / 398	0,486 / 0,062	0,30	< 0,001
служебные слова	136 / 138	0,979 / 0,968	0,18	0,009
якоря func	70 / 197	0,965 / 0,189	0,56	< 0,001
якоря mixed	131 / 145	0,964 / 0,150	0,54	< 0,001
якоря content	60 / 194	0,361 / 0,451	-0,13	0,12

Таблица 2. Срезы по классу части речи слова и по типу якорей конструкции.




Рис. 3. Средняя affinity (chain) якорей и заполнителей по конструкциям, сгруппированным по типу якорей.

По синтаксическому типу конструкции эффект положителен в 9 из 10 типов. Исключение — «Clause or XP with parentheticals» ($\delta = -0,36$): сюда входят вводные «(я) смотрю, CI» и «Сто пудов/стопудово XP», у которых якорь стоит в синтаксически свободной позиции.

3.3. Внутри и вне конструкции




Рис. 4. Средняя affinity (chain) каждой словоформы-якоря в примерах конструктиконе и в предложениях НКРЯ. Точки выше диагонали — формы, более предсказуемые внутри конструкции.

Вариант	Форм	Внутри > вне	Медиана	внутри / вне	Средняя разность [95% ДИ]	Уилкоксон p (г)
single	47	30		0,729 / 0,476	+0,14 [0,06; 0,22]	0,0009 (0,54)
chain	60	33		0,557 / 0,387	+0,11 [0,04; 0,18]	0,008 (0,39)
chain, фильтр приме- ним	37	23		0,765 / 0,488	+0,16 [0,08; 0,26]	0,0014 (0,58)

Таблица 3. Словоформа внутри конструкции против той же словоформы в НКРЯ. г — rank-biserial корреляция.

Та же словоформа предсказуемее внутри конструкции (Рис. 4, Таблица 3). Сильнее всего это видно у форм, которые без конструкции почти непредсказуемы: «коль» (0,95 против 0,07), «разом» (0,90 против 0,08), «ужас» в «тихий ужас» (0,84 против 0,17), «фронтам» в «по всем фронтам» (0,66 против 0,08). Там, где фильтр «вне конструкции» применим (конструкции с несколькими якорями), эффект сильнее, чем в целом. Это ожидаемо: для одноякорных конструкций часть предложений НКРЯ, скорее всего, сама содержит ту же конструкцию.

3.4. Вариант по лемме

У изменяемых якорей вероятность лексемы выше вероятности точной формы: медиана 0,967 против 0,954, прирост больше 0,01 у 16% якорей. Крупные приросты показывают, что модель узнаёт лексему, но ошибается в форме: «получилось» (0,32 → 0,98), «такой»/«такая» (0,37 → 0,97), «всё/все» (0,14 → 0,51). Основные выводы на этот вариант не опираются.

3.5. Качественный разбор

Самые непредсказуемые якоря — идиоматические и экспрессивные единицы: «худо-бедно» и «стопудово» (affinity ≈ 0), «бельмеса». Для «ни бельмеса не смыслите» модель предлагает «ф...», «х...», «фиг», то есть другие заполнители той же схемы «ни X не V». Модель узнаёт конструкцию, но не конкретную лексему. Самые предсказуемые «заполнители» — служебные слова внутри слотов размером с клаузу (C1): «не», «о», «от», «при» с affinity ≈ 0,999. Отдельно стоит «всем скандалам скандал»: второе «скандал» (0,999) является заполнителем, но оно копирует первый слот.

Это та же предсказуемость, порождённая конструкцией, что и у NPN в §6 исходной статьи. Полный список (15 + 15 примеров с топ-5 предсказаниями) лежит в `results/tables/qualitative.md`.

4. Обсуждение

Основной результат Rozner и соавт. воспроизводится на русском языке и для другой модели: якоря конструкций имеют более высокую *global affinity*, чем заполнители слотов и чем те же словоформы вне конструкции. Размер эффекта средний ($\delta \approx 0,38$), он устойчив к способу обработки мультитокенных слов и сохраняется у знаменательных слов после контроля части речи.

Однако на уровне конструкций эффект держится на служебных и смешанных якорях. Если все якоря конструкции знаменательные, модель восстанавливает их не лучше, чем заполнители. Возможное объяснение такое: *global affinity* измеряет предсказуемость конкретной словоформы, а знаменательный якорь часто является редкой лексемой («бельмеса», «худобедно»), и модель подставляет вместо него другое слово той же схемы. На 30 конструкциях (по 10 на каждый тип якорей) это наблюдение предварительное.

5. Ограничения

- **Отбор и якоря.** 30 конструкций из 4001, по 5 примеров. Список якорей зафиксирован заранее и не исправлялся. В нём есть огрехи извлечения: у «Слышь (ты), Cl» якорем указано только необязательное «ты», а «Слышь» не указано; у «Сделать-Imр милость» потерян якорь «сделать»; у «Ни бельмеса ...» есть артефакты «по-Adj» и «ки».
- **Сопоставление по лемме** для знаменательных якорей в словарной форме — это отступление от спецификации: в данных нет тегов -Tag, на которые она рассчитывала.
- **Размеры групп в НКРЯ.** Многие формы встречаются в конструктиконе 1–2 раза, поэтому средние «внутри» по отдельным формам шумные. Тест по формам придаёт им тот же вес, что и частым формам.
- **Фильтр «вне конструкции»** неприменим к 23 формам одноякорных конструкций.
- **Вариант lemma** — нижняя оценка: мультитокенные формы лексемы не учитываются.
- **Слоты-клаузы.** Заполнитель Cl — это целая клауза, поэтому в группу заполнителей попадают служебные слова, не связанные с конструкцией. Контроль части речи частично это компенсирует.

6. Отличия от оригинала

Модель `ai-forever/ruRoberta-large` вместо `roberta-large`. Русский конструктикон вместо CoGS. Две явные базовые линии (заполнители и НКРЯ). Мультитокенное расширение `chain`. Вариант `lemma` для изменяемых якорей. *Local affinity*, JSD-матрицы, анализ «так/настолько ... что» и аналоги MAGPIE/NPN в этот проход не входят.

7. Воспроизводимость

Код лежит в `scripts/`: `parse_constructicon.py` → `fetch_rnc.py` → `score.py` → `analyze.py` → `figures.py`. Юнит-тесты лежат в `tests/`. Итоговые числа — в `results/summary.json`, таблицы — в `results/tables/`. Ответы НКРЯ заэкшированы в `data/raw/rnc/`. Весь прогон занимает около 20 минут на 4 ядрах CPU.